Final Task

Analisis *Differential Expression Analysis* (DEG)

Oleh: Nyoman Yudi Antara

Pendahuluan

Ekspresi gen merupakan proses biologis fundamental yang memungkinkan informasi genetik yang tersimpan dalam DNA diekspresikan menjadi molekul RNA dan selanjutnya diterjemahkan menjadi protein fungsional. Proses ini mencakup tahap transkripsi (DNA menjadi RNA) dan translasi (RNA menjadi protein), yang dikendalikan secara ketat oleh berbagai mekanisme regulasi seperti faktor transkripsi, modifikasi epigenetik, serta regulasi pascatranskripsi dan pascatranslasi. Regulasi ekspresi gen memastikan bahwa gen tertentu diaktifkan atau direpresi pada waktu, lokasi, dan tingkat yang sesuai dengan kebutuhan fisiologis sel. Meskipun seluruh sel dalam organisme multiseluler memiliki materi genetik yang sama, perbedaan pola ekspresi gen menghasilkan diferensiasi sel dan fungsi biologis yang beragam (NIH, 2026; Segundo-Val & Sanz-Lozano, 2016). Ekspresi gen dapat diketahui dengan beberapa metode seperti qPCR, Microarray, dan RNA sequencing yang ketiganya dapat menilai level atau kadar ekspresi suatu gen yang ingin diketahui. Studi komprehensif mengenai ekspresi gen disebut transkriptomik (Dong & Chen, 2013; Volgin, 2013).

Ekspresi gen atau *Differential Expression Analysis* (DEG) dapat dilakukan menggunakan beberapa data seperti microarray ataupun RNA sequencing. Terdapat beberapa metode bioinformatik yang dapat digunakan untuk menganalisis ekspresi gen. Tugas ini ditujukan untuk mempelajari dan memahami proses analisis ekspresi gen atau *Differential Expression Analysis* (DEG) menggunakan dataset yang ada di NCBI terutama GEO *(Gene Expression Omnibus)*.

Metode

Metode yang digunakan dalam tugas ini adalah menganalisis dataset yang ada di GEO mencari dan menggunakan dataset GEO dengan kode GSE 20864. GSE20864 merupakan dataset gene expression profiling dari pasien yang mengalami *Systematic Lupus Erythematosu* (SLE). Sampel terdiri dari dua kategori yaitu normal dan pasien yang mengalami SLE. Analisis tugas kali ini menggunakan bahasa pemrograman R sebagai platform untuk menganalisis differensial ekspresi gen yang dilanjutkan dengan menganalisis gene ontology (GO) dan analisis Pathway KEGG. Skrip hasil analisis selanjutnya dapat diakses di github: https://github.com/yudilearn/Final-Task-Bioinformatic-analysis-of-SLE.git

Hasil

Hasil analisis GSE20864 menunjukkan bahwa distribusi ekspresi gen per sampel tredistribusi normal antar sampel (Gambar 1) baik dalam kondisi sehat maupun yang mengalami SLE.

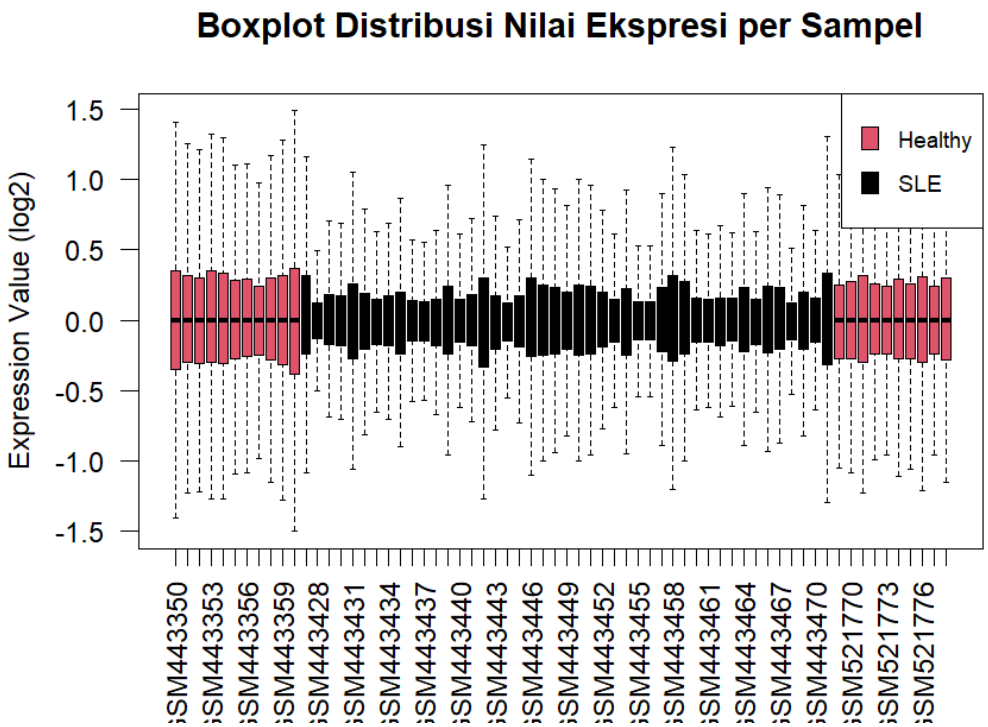

Gambar 1. Distribusi ekspresi gen per sampel

Terdapat 66 (45 sampel orang sehat dan 21 sampel yang mengalami SLE) sampel yang dianalisis yang disimbolkan dengan kode GSM yang merupakan kode yang digunakan untuk sampel yang dianalisis menggunakan Microarray. Boxplot distribusi nilai ekspresi per sampel menunjukkan bahwa median nilai ekspresi antar sampel relatif sejajar dan berada pada kisaran yang hampir sama. Sebaran data (interquartile range) pada masing-masing sampel juga tampak seragam, yang menunjukkan konsistensi distribusi ekspresi antar sampel. Secara visual, tidak terlihat adanya sampel dengan distribusi yang menyimpang secara mencolok. Hal ini mengindikasikan bahwa data memiliki kualitas yang cukup baik dan layak untuk dilanjutkan ke tahap analisis berikutnya. Grafik dibuat menggunakan metode boxplot pada base R, di mana setiap kolom matriks ekspresi diplot sebagai satu sampel, dengan pewarnaan berdasarkan kelompok Healthy dan SLE.

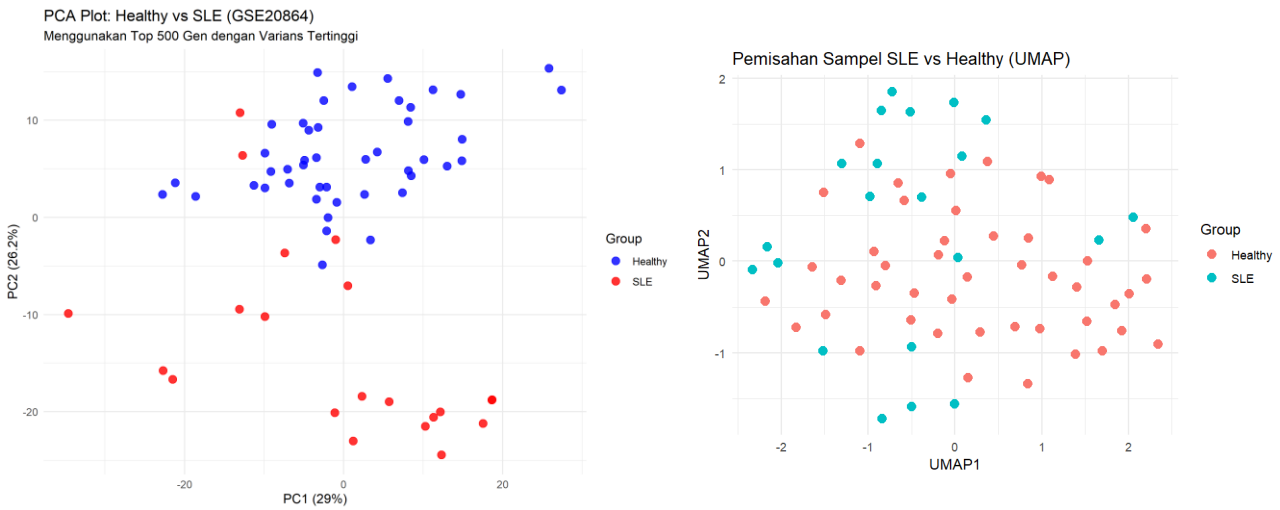

Gambar 2. Hasil pemetaan gen berdasarkan PCA *(Principle Component Analysis)* dan UMAP *(Uniform Manifold Approximation and Projection)*

Pada grafik PCA *(Principal Component Analysis)* di sebelah kiri, terlihat bahwa sampel dari kelompok Healthy (biru) dan SLE (merah) memiliki pemisahan yang jelas, terutama pada PC2 yang menjelaskan sekitar 26,2% dari variasi data. Sebagian besar titik untuk Healthy terkumpul di bagian atas plot, sementara titik SLE lebih banyak berada di bagian bawah, menunjukkan adanya perbedaan ekspresi genetik yang cukup signifikan antara kedua kelompok tersebut. Meskipun demikian, beberapa titik masih tumpang tindih, yang bisa disebabkan oleh heterogenitas sampel atau perbedaan teknis seperti *batch effect.* Secara keseluruhan, PCA memberikan gambaran bahwa perbedaan antara kelompok sehat atau Healthy dan SLE dapat ditangkap dengan baik melalui analisis varians terbesar pada dua komponen utama ini. Di sisi lain, grafik UMAP *(Uniform Manifold Approximation and Projection)* di sebelah kanan menunjukkan hasil yang berbeda. Meskipun ada beberapa area di mana titik-titik Healthy dan SLE terlihat lebih terpisah, umumnya terdapat banyak overlap antara kedua kelompok. UMAP, yang berfokus pada mempertahankan struktur lokal data, tidak menunjukkan pemisahan yang tegas seperti yang terlihat pada PCA. Hal ini mungkin disebabkan oleh kurangnya pemisahan yang jelas antara kedua kelompok pada tingkat lokal, atau pengaturan parameter UMAP yang belum optimal. Perbedaan ini menyoroti bagaimana PCA lebih efektif untuk menangkap perbedaan global yang besar antara kelompok, sementara UMAP lebih fokus pada kedekatan sampel berdasarkan struktur lokal (Gambar 2) (Cottrell et al., 2024; Cristian et al., 2024). Perbedaan ini selanjutnya dapat dianalisis menggunakan pendekatan vulcano plot untuk melihat gen uang mengalami penurunan atau donwregulated atau peningkatan upregulated secara signifikan.

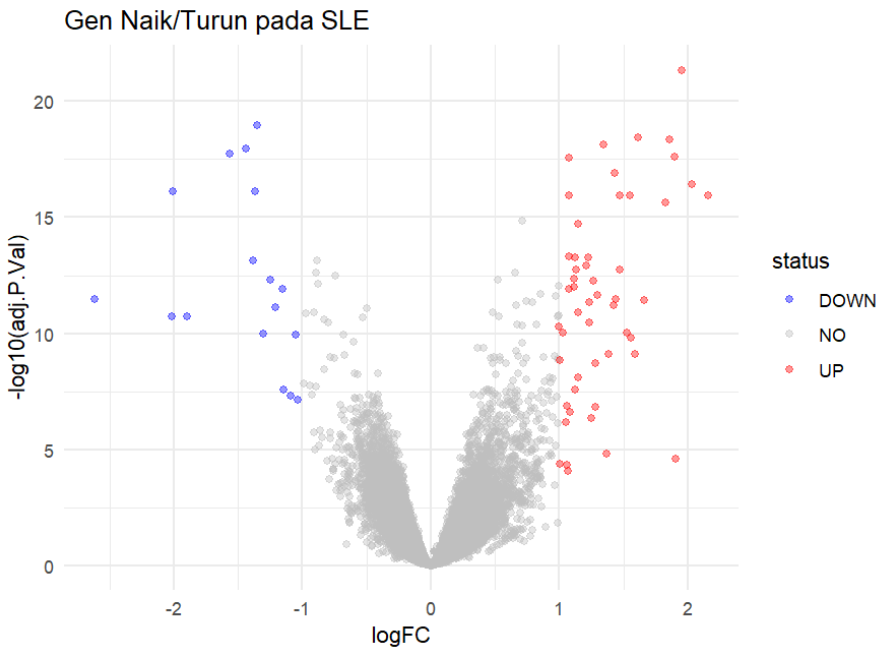

Gambar 3. Volcano plot gen-gen yang mengalami upregulated dan downregulated serta tidak mengalami perubahan signifikan

Volcano plot yang ditampilkan menggambarkan hasil analisis diferensial ekspresi gen pada kondisi SLE dibandingkan dengan kelompok Healthy. Pada sumbu X, logFC menunjukkan perubahan ekspresi gen, dengan nilai positif yang menunjukkan gen lebih terekspresi pada SLE, dan nilai negatif menunjukkan gen lebih rendah ekspresinya pada SLE. Sumbu Y, yaitu **-** log10(adj.P.Val)**,** mengindikasikan signifikansi statistik dari perbedaan ekspresi, dengan nilai yang lebih tinggi menunjukkan hasil yang lebih signifikan. Titik merah (UP) menunjukkan gen yang lebih terekspresi pada SLE dengan nilai p yang signifikan, sementara titik biru (DOWN) menunjukkan gen yang lebih rendah ekspresinya pada SLE dengan nilai p yang juga signifikan. Titik abu-abu (NO) mewakili gen yang tidak menunjukkan perubahan signifikan. Dari grafik ini, terlihat bahwa ada sejumlah gen yang mengalami perubahan ekspresi yang signifikan antara SLE dan Healthy, baik yang meningkat (UP) maupun menurun (DOWN), yang dapat menjadi kandidat penting untuk penelitian lebih lanjut dalam memahami patogenesis SLE. Gen-gen yang mengalami upregulated maupun down regulated berdasarkan kelompok Healthy dan SLE pada masing-masing sampel ditunjukkan pada gambar 4.

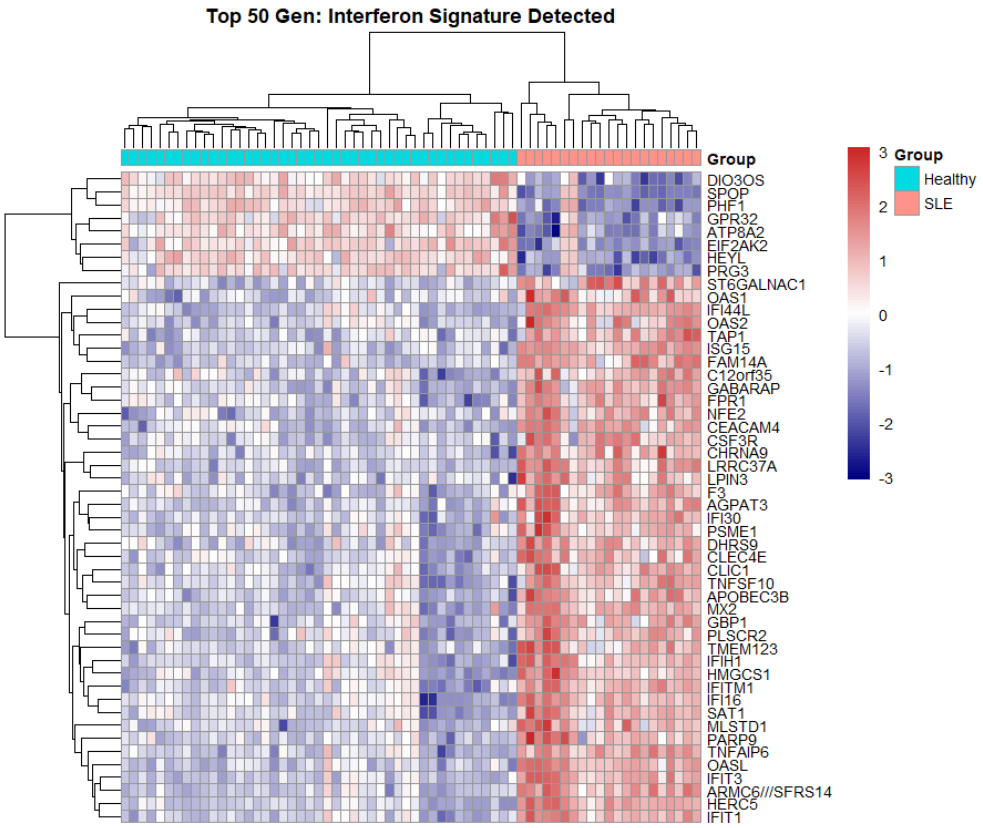

Gambar 4. Heatmap gen yang mengalami upregulated dan downregulated pada kelompok Healthy vs SLE

Heatmap yang ditampilkan menunjukkan ekspresi 50 gen teratas yang terdeteksi dalam tanda tangan interferon pada SLE dan kelompok Healthy, dengan warna yang mewakili tingkat ekspresi gen pada skala log2. Warna merah menunjukkan ekspresi gen yang lebih tinggi, sementara **biru** menunjukkan ekspresi yang lebih rendah. Dari heatmap ini, dapat dilihat bahwa sebagian besar gen pada kelompok SLE (terutama di sisi kanan) menunjukkan ekspresi yang lebih tinggi dibandingkan dengan kelompok Healthy (di sisi kiri). Gen-gen yang terkait dengan interferon seperti OAS1, IFIT1, dan ISG15 menunjukkan ekspresi yang sangat tinggi pada SLE (Feng et al., 2006), yang menunjukkan adanya aktivasi jalur interferon yang kuat pada kelompok ini. Pengelompokan berdasarkan *hierarchical clustering* juga menunjukkan bahwa sampel dari kelompok Healthy dan SLE terpisah dengan cukup jelas berdasarkan pola ekspresi gen. Kelompok SLE menunjukkan klaster yang lebih homogen dengan ekspresi interferon yang tinggi, sementara kelompok Healthy memiliki variasi ekspresi yang lebih rendah dan lebih terdistribusi. Ini mendukung hipotesis bahwa aktivasi interferon memainkan peran penting dalam patogenesis SLE, dan gen-gen terkait interferon dapat digunakan sebagai biomarker untuk mengidentifikasi dan memahami mekanisme penyakit ini (Pazhouhandeh & Yu, 2024).

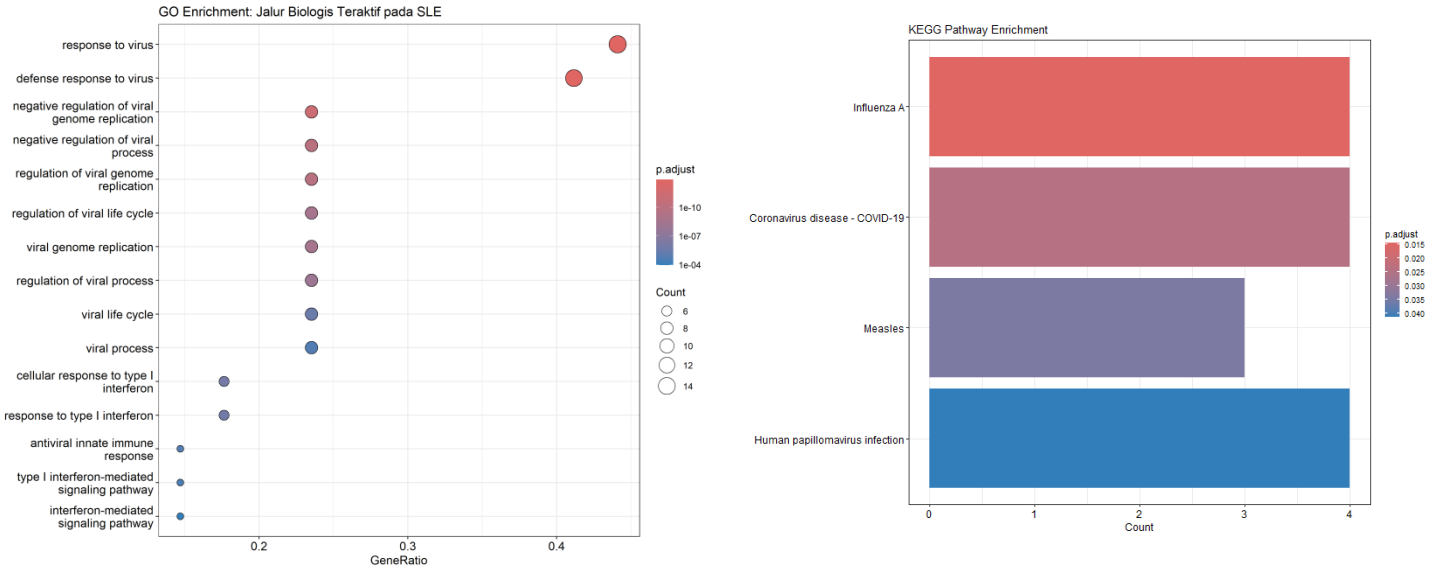

Gambar 5. Hasil GO Enrichment dan Jalur KEGG

Berdasarkan hasil analisis menggunakan GO Enrichment dan Jalur KEGG, Hasil GO enrichment analysis menunjukkan bahwa gen-gen yang mengalami perubahan ekspresi pada SLE secara signifikan berkaitan dengan proses biologis yang berhubungan dengan respons imun terhadap infeksi virus dan aktivasi interferon. Beberapa proses biologis yang paling diperkaya antara lain *response to virus*, *defense response to virus*, *viral genome replication*, serta *response to type I interferon*. Nilai gene ratio yang cukup tinggi pada beberapa istilah GO menunjukkan bahwa proporsi gen yang terlibat dalam jalur tersebut cukup besar dibandingkan jumlah gen yang dianalisis. Selain itu, nilai p.adjust yang sangat kecil mengindikasikan bahwa keterkaitan ini signifikan secara statistik. Temuan ini memperkuat hasil analisis sebelumnya, terutama dari heatmap yang menunjukkan adanya interferon signature, sehingga menunjukkan bahwa aktivasi jalur interferon dan respons antivirus merupakan mekanisme biologis penting yang berperan dalam patogenesis SLE.

Sementara itu, hasil KEGG pathway enrichment analysis menunjukkan bahwa gen-gen yang teridentifikasi juga berasosiasi dengan beberapa jalur penyakit yang berkaitan dengan infeksi virus, seperti *Influenza A*, *Coronavirus disease (COVID-19)*, *Measles*, dan *Human papillomavirus infection*. Meskipun jalur tersebut dinamai berdasarkan penyakit infeksi tertentu, interpretasinya bukan berarti pasien SLE mengalami infeksi tersebut, tetapi menunjukkan bahwa gen-gen yang terlibat dalam respons imun antivirus juga aktif pada kondisi SLE. Hal ini mengindikasikan bahwa mekanisme molekuler yang biasanya digunakan tubuh untuk melawan infeksi virus, terutama yang dimediasi oleh interferon dan sistem imun bawaan, juga berperan dalam proses inflamasi dan disregulasi imun pada SLE. Dengan demikian, hasil KEGG pathway ini semakin mendukung bahwa aktivasi jalur imun antiviral dan interferon merupakan karakteristik molekuler utama pada SLE.

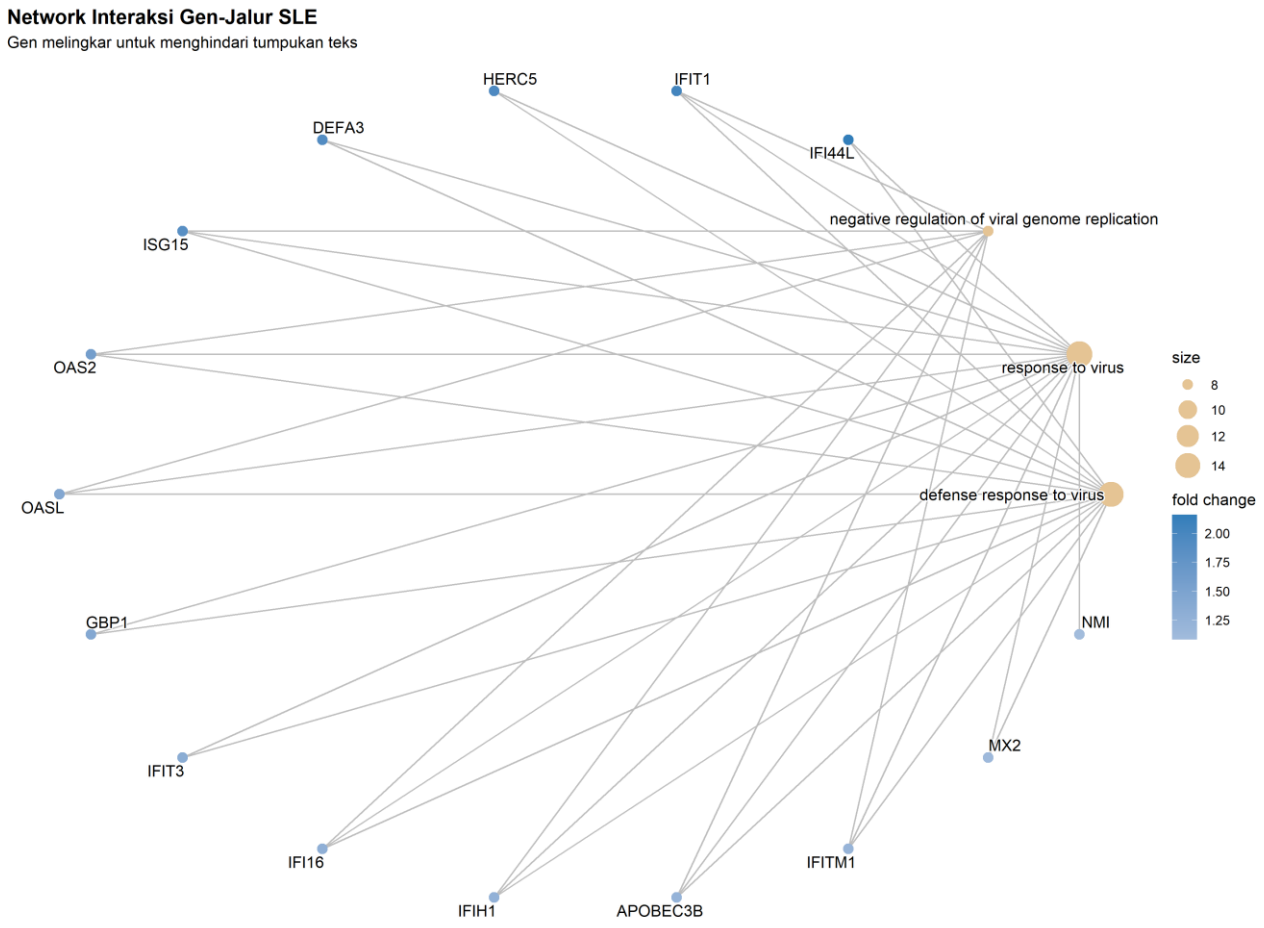

Gambar 6. Interaksi gen jalur SLE

Cnet plot (concept–gene network) ini menggambarkan hubungan antara gen-gen yang mengalami perubahan ekspresi dengan proses biologis hasil analisis GO enrichment pada kondisi SLE. Pada grafik tersebut, node berwarna biru merepresentasikan gen, sedangkan node berwarna krem menunjukkan proses biologis yang diperkaya. Ukuran node proses biologis mencerminkan jumlah gen yang terlibat pada proses tersebut. Dari jaringan ini terlihat bahwa beberapa proses biologis utama seperti “response to virus”, “defense response to virus”, dan “negative regulation of viral genome replication” terhubung dengan banyak gen, yang menunjukkan bahwa jalur respons antivirus merupakan proses biologis yang paling dominan dalam dataset ini. Gen-gen seperti ISG15, OAS2, OASL, IFIT1, IFIT3, IFI16, IFI44L, IFITM1, MX2, dan GBP1 terhubung dengan beberapa proses biologis sekaligus, menandakan bahwa gen-gen tersebut memiliki peran penting dalam regulasi respons imun terhadap virus (Oliveira et al., 2014).

Selain itu, jaringan interaksi ini juga menunjukkan bahwa banyak gen yang terlibat merupakan interferon-stimulated genes (ISGs), yang biasanya diaktifkan oleh sinyal interferon tipe I sebagai bagian dari respons imun bawaan terhadap infeksi virus. Keterhubungan gen-gen tersebut dengan beberapa proses biologis secara bersamaan menunjukkan adanya koordinasi regulasi molekuler dalam sistem imun pada SLE. Pola ini mendukung hasil analisis sebelumnya

seperti heatmap dan enrichment analysis yang menunjukkan adanya interferon signature yang kuat pada SLE, sehingga mengindikasikan bahwa aktivasi jalur interferon dan respons antivirus merupakan mekanisme biologis utama yang berkontribusi terhadap patogenesis penyakit ini.

Referensi

Cottrell, S., Wang, R., & Wei, G. W. (2024). PLPCA: Persistent Laplacian-Enhanced PCA for Microarray Data Analysis. *Journal of Chemical Information and Modeling*, *64*(7), 2405–2420. https://doi.org/10.1021/acs.jcim.3c01023

Cristian, P. M., Aarón, V. J., Esquivel-Hernandez, D. A., Estrella, M. L. Y., Daniel, N. R., David, G. V., Edgar, M., Paul, S. C. J., & Osbaldo, R. A. (2024). Diffusion on PCA-UMAP Manifold: The Impact of Data Structure Preservation to Denoise High-Dimensional Single-Cell RNA Sequencing Data. *Biology*, *13*(7). https://doi.org/10.3390/biology13070512

Dong, Z. C., & Chen, Y. (2013). Transcriptomics: Advances and approaches. *Science China Life Sciences*, *56*(10), 960–967. https://doi.org/10.1007/s11427-013-4557-2

Feng, X., Wu, H., Grossman, J. M., Hanvivadhanakul, P., FitzGerald, J. D., Park, G. S., Dong, X., Chen, W., Kim, M. H., Weng, H. H., Furst, D. E., Gorn, A., McMahon, M., Taylor, M., Brahn, E., Hahn, B. H., & Tsao, B. P. (2006). Association of increased interferon-inducible gene expression with disease activity and lupus nephritis in patients with systemic lupus erythematosus. *Arthritis & Rheumatism*, *54*(9), 2951–2962. https://doi.org/https://doi.org/10.1002/art.22044

NIH. (2026). *Gene Expression*. National Human Genome Research Institute. https://www.genome.gov/genetics-glossary/Gene-Expression

Oliveira, L., Sinicato, N. A., Postal, M., Appenzeller, S., & Niewold, T. B. (2014). Dysregulation of antiviral helicase pathways in systemic lupus erythematosus. *Frontiers in Genetics*, *5*(NOV), 1–6. https://doi.org/10.3389/fgene.2014.00418

Pazhouhandeh, M., & Yu, D. (2024). Interferon disrupts immune and tissue homeostasis in SLE via CXCL13. *Nature Reviews Rheumatology*, *20*(12), 745–746. https://doi.org/10.1038/s41584-024-01164-y

Segundo-Val, I. S., & Sanz-Lozano, C. S. (2016). Introduction to the Gene Expression Analysis. *Methods in Molecular Biology (Clifton, N.J.)*, *1434*, 29–43. https://doi.org/10.1007/978-1-4939-3652-6_3

Volgin, D. V. (2013). Gene Expression: Analysis and Quantitation. *Animal Biotechnology: Models in Discovery and Translation*, 307–325. https://doi.org/10.1016/B978-0-12-416002-6.00017-1

Cottrell, S., Wang, R., & Wei, G. W. (2024). PLPCA: Persistent Laplacian-Enhanced PCA for Microarray Data Analysis. *Journal of Chemical Information and Modeling*, *64*(7), 2405–2420. https://doi.org/10.1021/acs.jcim.3c01023

Cristian, P. M., Aarón, V. J., Esquivel-Hernandez, D. A., Estrella, M. L. Y., Daniel, N. R., David, G. V., Edgar, M., Paul, S. C. J., & Osbaldo, R. A. (2024). Diffusion on PCA-UMAP Manifold: The Impact of Data Structure Preservation to Denoise High-Dimensional Single-

Cell RNA Sequencing Data. *Biology*, *13*(7). https://doi.org/10.3390/biology13070512

Dong, Z. C., & Chen, Y. (2013). Transcriptomics: Advances and approaches. *Science China Life Sciences*, *56*(10), 960–967. https://doi.org/10.1007/s11427-013-4557-2

Feng, X., Wu, H., Grossman, J. M., Hanvivadhanakul, P., FitzGerald, J. D., Park, G. S., Dong, X., Chen, W., Kim, M. H., Weng, H. H., Furst, D. E., Gorn, A., McMahon, M., Taylor, M., Brahn, E., Hahn, B. H., & Tsao, B. P. (2006). Association of increased interferon-inducible gene expression with disease activity and lupus nephritis in patients with systemic lupus erythematosus. *Arthritis & Rheumatism*, *54*(9), 2951–2962. https://doi.org/https://doi.org/10.1002/art.22044

NIH. (2026). *Gene Expression*. National Human Genome Research Institute. https://www.genome.gov/genetics-glossary/Gene-Expression

Pazhouhandeh, M., & Yu, D. (2024). Interferon disrupts immune and tissue homeostasis in SLE via CXCL13. *Nature Reviews Rheumatology*, *20*(12), 745–746. https://doi.org/10.1038/s41584-024-01164-y

Segundo-Val, I. S., & Sanz-Lozano, C. S. (2016). Introduction to the Gene Expression Analysis. *Methods in Molecular Biology (Clifton, N.J.)*, *1434*, 29–43. https://doi.org/10.1007/978-1-4939-3652-6_3

Volgin, D. V. (2013). Gene Expression: Analysis and Quantitation. *Animal Biotechnology: Models in Discovery and Translation*, 307–325. https://doi.org/10.1016/B978-0-12-416002-6.00017-1